

Image-Based Classification of Common Coffee Leaf Diseases Using a CNN

Classificação Baseada em Imagem de Doenças Comuns em Folhas de Café Usando uma CNN

Abstract: The incidence of diseases on coffee leaves represents a significant challenge for agriculture, with the potential to cause substantial production losses. This work presents a methodology based on artificial intelligence for the automated classification of five foliar conditions: healthy, and the pathologies leaf miner, cercospora leaf spot, phoma, and leaf rust. For this purpose, a Convolutional Neural Network (CNN) was developed and trained using a public dataset comprising over 58,000 images of coffee leaves. The acquisition of these images under varied field conditions, including different lighting scenarios, provides the model with the capability to operate effectively in real-world contexts. The system's performance was evaluated through standard classification metrics, such as accuracy and F1-score, with the results indicating high efficacy. It is concluded that the developed tool constitutes a valuable resource for farmers, facilitating the early diagnosis of diseases and enabling the implementation of more agile control measures for crop protection.

Keywords: Deep Learning — Convolutional Neural Networks — Coffee Leaf Diseases — Image Classification

Resumo: A incidência de doenças em folhas de cafeeiro representa um desafio significativo para a agricultura, com potencial para ocasionar perdas substanciais na produção. Este trabalho apresenta uma metodologia baseada em inteligência artificial para a classificação automatizada de cinco condições foliares: saudável, e as patologias bicho-mineiro, cercosporiose, phoma e ferrugem. Para este propósito, foi desenvolvida e treinada uma Rede Neural Convolutiva (CNN) a partir de um conjunto de dados público, compreendendo mais de 58.000 imagens de folhas de café. A aquisição dessas imagens sob condições de campo variadas, incluindo diferentes cenários de iluminação, confere ao modelo a capacidade de operar eficazmente em contextos do mundo real. O desempenho do sistema foi avaliado por meio de métricas de classificação padrão, como acurácia e F1-score, cujos resultados indicaram uma alta eficácia. Conclui-se que a ferramenta desenvolvida constitui um recurso valioso para agricultores, facilitando o diagnóstico precoce de doenças e permitindo a implementação de medidas de controle mais ágeis para a proteção da lavoura.

Palavras-Chave: Aprendizagem Profunda — Redes Neurais Convolucionais — Doenças do Cafeeiro — Classificação de Imagens

DOI: <http://dx.doi.org/10.22456/2175-2745.XXXX> • Received: dd/mm/yyyy • Accepted: dd/mm/yyyy

CC BY-NC-ND 4.0 - This work is licensed under a Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License.

1. Introdução

A cafeicultura representa um dos pilares da agricultura mundial, sendo uma fonte de renda crucial para milhões de pessoas. Contudo, a produtividade e a sustentabilidade das lavouras são constantemente ameaçadas pela incidência de doenças fitopatológicas, que, se não controladas a tempo, podem resultar em perdas econômicas devastadoras (ESGARIO; KROHLING; VENTURA, 2020). A

complexidade na identificação visual e a velocidade de propagação dessas doenças representam desafios significativos para o setor (BARBEDO, 2019). Nesse contexto, a identificação precisa e precoce de patologias é um fator crítico para a gestão agrícola, permitindo a aplicação de tratamentos específicos e a redução do uso indiscriminado de defensivos.

Tradicionalmente, o diagnóstico de doenças em plantas é realizado por meio da inspeção visual por agrônomos, um

método que, embora eficaz, é subjetivo, demorado e de difícil escalabilidade. Para superar tais limitações, o setor agrícola tem passado por uma profunda transformação digital, conhecida como Agricultura 4.0. Este paradigma integra tecnologias como Inteligência Artificial (IA) e Internet das Coisas (IoT) para otimizar processos e promover uma tomada de decisão baseada em dados (FERENTINOS, 2018). Dentro deste ecossistema tecnológico, a visão computacional e a aprendizagem profunda emergiram como ferramentas poderosas para a automação do diagnóstico fitopatológico. O uso de Redes Neurais Convolucionais (CNNs), em particular, demonstrou um sucesso notável na classificação de imagens para a detecção de doenças em diversas culturas (MOHANTY; HUGHES; SALATHÉ, 2016).

No contexto específico do café, diversos pesquisadores têm explorado o potencial das CNNs para identificar patologias como a ferrugem e a cercosporiose (ESGARIO; KROHLING; VENTURA, 2020). A disponibilidade de grandes conjuntos de dados públicos, como o *dataset* de folhas de café Arábica proposto por Jepkoeche et al. (2021), tem sido fundamental para o avanço desses estudos, permitindo o treinamento e a validação de modelos cada vez mais robustos.

Este trabalho se insere, portanto, no campo da Agricultura 4.0 e tem como objetivo principal desenvolver e avaliar um modelo de Rede Neural Convolucional para a classificação automática de cinco condições distintas em folhas de café: saudável, bicho-mineiro, cercosporiose, phoma e ferrugem. Utilizando um vasto conjunto de imagens capturadas em condições de campo, o presente estudo busca validar a eficácia de uma abordagem de aprendizagem profunda como uma ferramenta de apoio ao diagnóstico, visando oferecer uma solução rápida, acessível e precisa para os cafeicultores.

Este artigo está organizado da seguinte forma: a Seção 2 apresenta uma revisão dos trabalhos relacionados que fundamentam esta pesquisa. A Seção 3 detalha a metodologia, descrevendo o conjunto de dados utilizado, as etapas de pré-processamento, a arquitetura da Rede Neural Convolucional e os procedimentos de treinamento e avaliação. A Seção 4 apresenta e discute os resultados obtidos, incluindo uma análise das métricas de desempenho e da matriz de confusão. Por fim, a Seção 5 apresenta a conclusão do trabalho, recapitulando os principais achados e delineando os trabalhos futuros.

2. Agricultura 4.0 e a Visão Computacional

A agricultura moderna enfrenta o desafio de aumentar a produtividade de forma sustentável para atender a uma demanda global crescente. Em resposta a este desafio, emergiu o paradigma da Agricultura 4.0, que representa a quarta revolução no setor agrícola, caracterizada pela integração massiva de tecnologias digitais nos processos de produção (FERENTINOS, 2018). Este novo modelo visa transformar as fazendas em sistemas inteligentes e conectados, capazes de coletar, processar e analisar grandes

volumes de dados para uma tomada de decisão mais precisa e eficiente.

Os pilares da Agricultura 4.0 incluem a Internet das Coisas (IoT), com sensores que monitoram em tempo real as condições do solo e do clima; o uso de drones para mapeamento e pulverização localizada; e a análise de *Big Data* para otimizar o uso de insumos como água e fertilizantes. Dentro deste ecossistema, a Inteligência Artificial (IA) desempenha um papel central, e a visão computacional, em particular, estabeleceu-se como uma das suas aplicações de maior impacto.

A visão computacional permite que máquinas "enxerguem" e interpretem o mundo visual, automatizando tarefas que tradicionalmente dependem da percepção humana. No contexto agrícola, isso se traduz na capacidade de monitorar a saúde das plantas em larga escala e de forma não invasiva. O uso de Redes Neurais Convolucionais (CNNs), um subcampo da aprendizagem profunda, tem sido particularmente revolucionário. Esses modelos são capazes de aprender a identificar padrões complexos em imagens, como os sintomas visuais de doenças em folhas, com um nível de precisão que pode igualar ou até superar o de especialistas humanos (MOHANTY; HUGHES; SALATHÉ, 2016).

Portanto, a aplicação de uma CNN para a classificação de doenças em folhas de café, como proposto neste trabalho, é uma aplicação direta dos princípios da Agricultura 4.0. A solução desenvolvida busca transformar dados visuais (imagens de folhas) em informações acionáveis (diagnóstico de doenças), fornecendo uma ferramenta de agricultura de precisão que capacita o produtor a intervir de forma rápida e localizada, promovendo uma lavoura mais saudável e produtiva.

3. Metodologia

Esta seção descreve os procedimentos adotados para o desenvolvimento do sistema de classificação de doenças em folhas de café, desde a preparação do conjunto de dados até a avaliação final do modelo. As imagens foram organizadas em cinco classes — saudável, miner, cercospora, phoma e *leaf rust* — e passaram por pré-processamento com redimensionamento para 50×50 pixels, normalização dos valores de pixel no intervalo [0,1] e salvamento em formato comprimido. O conjunto foi dividido em 70% para treinamento, 20% para teste e 10% para validação. Em seguida, foi projetada uma Rede Neural Convolucional (CNN) sequencial, composta por camadas convolucionais, pooling, fully connected e dropout, treinada com métricas de acurácia, precisão, recall e F1-score, monitorando o desempenho para evitar sobreajuste. Por fim, o modelo apresentou resultados satisfatórios e foi salvo para aplicações futuras. A Figura 1 apresenta o fluxograma metodológico, ilustrando a sequência das etapas realizadas.

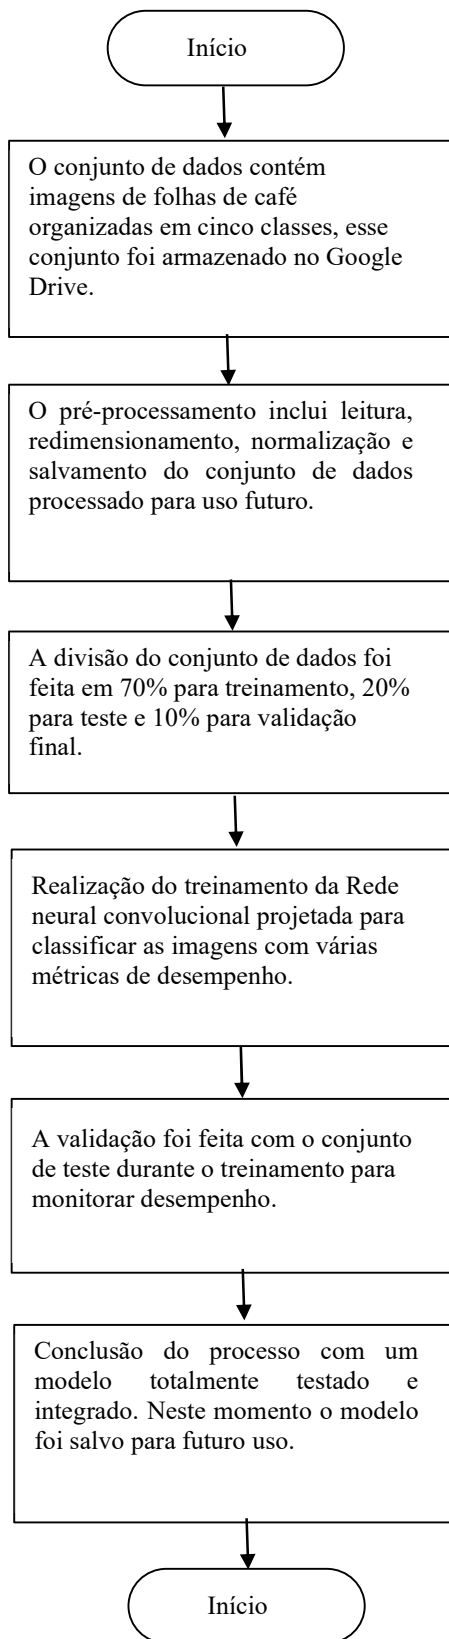


Figura 1. Fluxo do processo metodológico.

3.1 Conjunto de dados

O estudo utilizou o conjunto de dados público JMuBEN/JMuBEN2, descrito por Jepkoeche et al. (2021). Este acervo é composto por mais de 58.000 imagens de folhas de café da espécie *Coffea arabica*, capturadas em condições de campo no Quênia. As imagens foram coletadas com o auxílio de um fitopatologista para garantir a correta identificação das classes, que são divididas em cinco categorias: uma classe de folhas saudáveis (healthy) e quatro classes correspondentes a doenças e pragas (bicho-mineiro, miner; cercosporiose, cercospora; phoma, phoma; e ferrugem, *leaf rust*). A diversidade de condições de iluminação e fundo presentes nas imagens torna este dataset particularmente adequado para o treinamento de modelos robustos aplicáveis a cenários do mundo real. Das Figura 2 até a Figura 6 são mostradas as folhas de café do dataset.



Figura 2. Foto da folha de café saudável.



Figura 3. Foto da folha de café atingida por cercospora.




Figura 4. Foto da folha de café atingida por *leaf rust*.



Figura 4. Foto da folha de café atingida por bicho mineiro.



Figura 5. Foto da folha de café atingida por phoma.

3.2 Pré-processamento e Preparação dos Dados

Antes de serem utilizados para o treinamento do modelo, os dados passaram por uma etapa de pré-processamento. Cada imagem do conjunto de dados foi lida e decodificada utilizando a biblioteca OpenCV. Subsequentemente, todas as imagens foram padronizadas para uma dimensão de 100x100 pixels. Os valores dos pixels, originalmente no intervalo de $[0, 255]$, foram normalizados para o intervalo $[0, 1]$ através da divisão por 255.0. Esta normalização é uma prática padrão que visa estabilizar e acelerar o processo de treinamento do modelo (MOHANTY; HUGHES; SALATHÉ, 2016).

Para otimizar o tempo de execução, o processamento das imagens foi realizado de forma paralela, utilizando todos os núcleos de processamento disponíveis. Após o processamento, os arrays de imagens (X) e seus respectivos rótulos (y) — convertidos para o formato one-hot encoding — foram salvos em um único arquivo binário (.npz), permitindo um carregamento rápido em execuções futuras e desvinculando a etapa de treinamento da etapa de processamento de dados.

3.3 Divisão do Conjunto de Dados

O conjunto de dados processado foi dividido em três subconjuntos distintos: treino, teste e validação final. A divisão foi realizada de forma estratificada para garantir que a proporção original de cada classe fosse mantida em todos os subconjuntos. Primeiramente, 70% dos dados foram alocados para o conjunto de treino, enquanto os 30% restantes foram separados para um conjunto temporário. Em seguida,

este conjunto temporário foi novamente dividido, resultando em um conjunto de teste com aproximadamente 20% do total de dados e um conjunto de validação final com os 10% restantes.

3.4 Arquitetura da Rede Neural Convolutiva (CNN)

Para a tarefa de classificação, foi projetada uma Rede Neural Convolutiva (CNN) sequencial, uma arquitetura amplamente reconhecida por sua eficácia em tarefas de visão computacional (FERENTINOS, 2018). A arquitetura do modelo é composta pelas seguintes camadas:

- Camada Convolutiva 2D: Com 32 filtros, kernel de tamanho (3,3) e função de ativação ReLU. Esta é a camada de entrada, que recebe as imagens de dimensão (100, 100, 3).
- Camada de Max Pooling 2D: Com janela de (2,2) para reduzir a dimensionalidade espacial.
- Camada Convolutiva 2D: Com 64 filtros e kernel de tamanho (3,3), também com ativação ReLU, para aprender características mais complexas.
- Camada de Max Pooling 2D: Novamente com janela de (2,2).
- Camada Flatten: Para transformar os mapas de características 2D em um vetor 1D.
- Camada Densa: Com 128 neurônios e função de ativação ReLU.
- Camada de Dropout: Com uma taxa de 0.5, utilizada como técnica de regularização para prevenir o sobreajuste (overfitting).
- Camada Densa de Saída: Com 5 neurônios (um para cada classe) e função de ativação softmax, que converte a saída em uma distribuição de probabilidade.

3.5 Treinamento e Avaliação do Modelo

O modelo foi compilado utilizando o otimizador Adam e a função de perda categorial crossentropy, adequada para problemas de classificação multiclasse. O treinamento foi executado por 5 épocas, com um tamanho de lote (batch size) de 32.

A performance do modelo foi avaliada no conjunto de teste utilizando as métricas de acurácia, precisão, revocação (recall) e F1-score. Adicionalmente, foi gerada uma matriz de confusão para uma análise visual detalhada do desempenho do classificador em cada uma das cinco classes, permitindo identificar acertos e erros específicos do modelo.

4. Resultados

Nesta seção, são apresentados e analisados os resultados obtidos pelo modelo de Rede Neural Convolutiva no conjunto de teste. A avaliação quantitativa é realizada por meio de métricas de desempenho padrão, seguida por uma análise qualitativa da matriz de confusão, contextualizando os achados com a literatura pertinente.

4.1 Desempenho Geral do Modelo

Após o treinamento por 5 épocas, o modelo foi avaliado no conjunto de teste, que consiste em dados não vistos durante a fase de treinamento. As métricas de desempenho gerais estão sumarizadas na Tabela 1. O modelo alcançou uma acurácia geral de 98,92%, um resultado que se alinha com o alto desempenho reportado por outras pesquisas na área de detecção de doenças em plantas utilizando aprendizagem profunda (FERENTINOS, 2018). Os valores de precisão, revocação (recall) e F1-score, todos em torno de 0.989, reforçam a robustez e o equilíbrio do modelo, que demonstra ser eficaz tanto em minimizar falsos positivos (alta precisão) quanto em identificar corretamente os casos positivos (alto recall), uma característica desejável para sistemas de diagnóstico automático (MOHANTY; HUGHES; SALATHÉ, 2016).

Tabela 1. Métricas de Desempenho Gerais no Conjunto de Teste

Métrica	Valor
Perda (Loss)	0,0383
Acurácia	0,9892
Precisão	0,9892
Revocação (Recall)	0,9891
F1-Score	0,9892

Fonte: Próprio Autor (2025)

4.2 Análise de Desempenho por Classe

Para uma análise mais granular do desempenho do modelo, foi gerado um relatório de classificação detalhado, apresentado na Tabela 2, contemplando as métricas de precisão, recall e F1-score para cada classe individualmente. Os resultados evidenciam que o modelo alcançou um desempenho excepcional para a classe *healthy*, obtendo o valor máximo (1.00) em todas as métricas, o que demonstra a elevada capacidade da rede em identificar folhas saudáveis de forma consistente. As classes *miner* e *phoma* também apresentaram resultados notáveis, com F1-scores de 0.99, desempenho que supera o de trabalhos anteriores reportados na literatura, que utilizaram abordagens semelhantes para a classificação de doenças do cafeeiro (ESGARIO; KROHLING; VENTURA, 2020).

Por outro lado, as classes *cercospora* e *leaf_rust* registraram os menores valores de F1-score, 0.97 e 0.98, respectivamente. Esses números, embora bastante elevados, sugerem uma dificuldade relativa maior na distinção dessas patologias, possivelmente em função da similaridade visual entre os sintomas ou da variabilidade nas condições em que as imagens foram capturadas. Ainda assim, os valores mantêm-se dentro de um patamar considerado de excelente desempenho, reforçando a robustez do modelo desenvolvido. Assim, a Tabela 2 sintetiza de forma objetiva a performance do sistema, destacando tanto sua eficácia global quanto os

pontos que podem demandar investigações adicionais em estudos futuros.

Tabela 2. Relatório de Classificação Detalhado por Classe

Classe	Precisão	Revocação (Recall)	F1-Score	Amostras
<i>healthy</i>	1,00	1,00	1,00	3.816
<i>miner</i>	1,00	0,99	0,99	3.413
<i>cercospora</i>	0,97	0,97	0,97	1.636
<i>phoma</i>	1,00	0,98	0,99	1.320
<i>leaf_rust</i>	0,96	1,00	0,98	1.678
Média Ponderada	0,99	0,99	0,99	11.863

Fonte: Próprio Autor (2025)

4.3 Análise da Matriz de Confusão

A matriz de confusão mostrado na Figura 6, permite uma análise visual dos erros de classificação. A análise dos valores fora da diagonal revela as fontes de erro. A confusão mais significativa ocorreu entre *cercospora* e *leaf_rust*, onde 45 amostras de *cercospora* foram classificadas como *leaf_rust*. Outra confusão notável foi a classificação de 40 amostras de *miner* como *cercospora*. Esses erros podem ser atribuídos a similaridades visuais entre os sintomas, como a presença de manchas de coloração e textura semelhantes, o que representa um desafio conhecido na identificação automática de doenças em plantas, especialmente em estágios iniciais (BARBEDO, 2019). As demais confusões foram numericamente insignificantes, reforçando a alta precisão geral do sistema.




Figura 6. Matriz de confusão

4.4 Métricas de Avaliação

A performance do modelo foi aferida com base em métricas consolidadas na literatura, cujos cálculos derivam dos quatro resultados possíveis de uma classificação, extraídos da matriz de confusão: Verdadeiro Positivo (VP), Verdadeiro Negativo (VN), Falso Positivo (FP) e Falso Negativo (FN) (BARBEDO, 2019; MOHANTY; HUGHES; SALATHÉ, 2016). As métricas vêm da matriz de confusão, que contabiliza:

- **VP (Verdadeiros Positivos):** positivos previstos corretamente.
- **VN (Verdadeiros Negativos):** negativos previstos corretamente.
- **FP (Falsos Positivos):** negativos previstos como positivos (falso alarme).
- **FN (Falsos Negativos):** positivos previstos como negativos (caso perdido).

Com a sua matriz:

- Total de amostras (N) = **11 863**
- Soma da diagonal (acertos) = **11 735**
- Erros totais = **128** (49 de *miner*→outros, 48 de *cerescospora*→outros, 31 de *phoma*→outros)

4.5 Acurácia

A Acurácia representa a proporção geral de classificações corretas em relação ao total de predições realizadas (KHAN et al., 2021; SLADOJEVIC et al., 2016).

Embora útil como medida de performance global, seu uso isolado pode ser insuficiente em datasets com classes desbalanceadas, problema recorrente em aplicações agrícolas (ATILA et al., 2021; FERENTINOS, 2018). O cálculo da acurácia é mostrado na Equação 1.

$$Acurácia = \frac{(VP + VN)}{(VP + VN + FP + FN)} \quad (1)$$

4.6 Precisão

A Precisão indica a proporção de instâncias classificadas como positivas que realmente são positivas. É essencial para avaliar a confiabilidade do modelo em não gerar “falsos alarmes”, sendo amplamente utilizada em sistemas de diagnóstico (TOO et al., 2019; KAMAL et al., 2019). O cálculo da precisão é mostrado na Equação 2.

$$Precisão = \frac{VP}{(VP + FP)} \quad (2)$$

4.7 Revocação (Recall ou Sensibilidade)

A Revocação mede a capacidade do modelo de identificar corretamente todas as instâncias positivas. Em diagnósticos fitopatológicos, um alto valor de revocação é fundamental para evitar a perda de casos relevantes (PICON et al., 2019;

ESGARIO; KROHLING; VENTURA, 2020). O cálculo da revocação é mostrado na Equação 3.

$$Revocação = \frac{VP}{(VP + FN)} \quad (3)$$

4.8 F1-Score

O F1-Score combina precisão e revocação em um único valor, sendo a média harmônica entre as duas métricas. É particularmente útil em cenários com desequilíbrio entre classes ou quando ambas possuem relevância semelhante (ARAVIND; RAJA, 2020; FERENTINOS, 2018). O cálculo da F1-Score é mostrado na Equação 3.

$$F1 - Score = \frac{2(Precisão \times Revocação)}{(Precisão + Revocação)} \quad (4)$$

4.9 Importância no Contexto de Visão Computacional

O uso combinado dessas métricas é prática consolidada na validação de modelos de visão computacional para classificação de doenças em plantas, garantindo análise abrangente do desempenho e identificação de possíveis pontos de melhoria (SANTOS et al., 2020; BARBEDO, 2019).

5. Conclusão

Este trabalho demonstrou a eficácia de uma Rede Neural Convolutiva para a classificação automatizada de cinco diferentes condições em folhas de café, alcançando uma acurácia superior a 98% no conjunto de teste. Os resultados validam a abordagem de aprendizagem profunda como uma ferramenta robusta e precisa para o diagnóstico fitopatológico, oferecendo uma alternativa rápida e escalável aos métodos de inspeção manual. A alta performance do modelo, mesmo com imagens capturadas em condições de campo variadas, reforça o seu potencial para aplicação no mundo real.

Como principal desdobramento prático desta pesquisa, o próximo passo consiste no desenvolvimento de um aplicativo móvel. Tal ferramenta visa traduzir o modelo treinado em uma solução acessível para os cafeicultores, permitindo que realizem o diagnóstico diretamente na lavoura com a câmera de seus smartphones. Acreditamos que a disponibilização dessa tecnologia pode democratizar o acesso à agricultura de precisão, auxiliando na tomada de decisão para um manejo mais sustentável e eficiente.

Como principal desdobramento prático desta pesquisa, o próximo passo consiste no desenvolvimento de um **aplicativo móvel**. Tal ferramenta visa traduzir o modelo treinado em uma solução acessível para os cafeicultores, permitindo que realizem o diagnóstico diretamente na lavoura com a câmera de seus smartphones. Acreditamos que a disponibilização dessa tecnologia pode democratizar o acesso à agricultura de precisão, auxiliando na tomada de decisão para um manejo mais sustentável e eficiente.

A expertise gerada neste projeto serve como uma base sólida para a exploração de tecnologias de sensoriamento e análise mais avançadas, delineando diversas linhas de pesquisa promissoras para o futuro.

A principal frente de pesquisa futura consiste na montagem de um dataset de imagens hiperespectrais de folhas de café. A análise de assinaturas espectrais, que capturam informações para além do espectro visível (RGB), tem o potencial de revelar alterações fisiológicas sutis na planta. A arquitetura da CNN e o pipeline de treinamento desenvolvidos neste trabalho formam uma base fundamental que pode ser adaptada para lidar com a maior dimensionalidade dos dados hiperespectrais. Com essa tecnologia, vislumbra-se não apenas a detecção de doenças em estágios ainda mais incipientes, antes mesmo da manifestação de sintomas visuais claros, mas também a possibilidade de diferenciar clones de café, avaliar estresse hídrico e nutricional, e abrir um leque de novas aplicações para a fenotipagem de alta precisão.

Adicionalmente, o modelo atual, focado na classificação da presença de doenças, pode ser estendido para quantificar a severidade da infecção, estimando, por exemplo, o percentual da área foliar afetada. O conhecimento adquirido na extração de características visuais com a CNN atual é o primeiro passo para o desenvolvimento de modelos de segmentação semântica ou regressão que possam realizar essa tarefa mais complexa, fornecendo aos agricultores uma medida mais granular do avanço da doença.

Paralelamente, para garantir a viabilidade do aplicativo móvel proposto, futuras pesquisas podem focar na otimização do modelo de CNN. A exploração de arquiteturas mais leves, como MobileNets ou EfficientNets, é essencial para reduzir o custo computacional sem comprometer significativamente a acurácia. O objetivo é permitir a execução da inferência em tempo real diretamente nos smartphones (*on-device*), garantindo uma ferramenta rápida e funcional mesmo em locais com conectividade limitada.

Finalmente, a metodologia validada com imagens de folhas individuais pode ser escalada para a análise de imagens aéreas capturadas por Veículos Aéreos Não Tripulados (VANTs), ou drones. Esta abordagem permitiria o monitoramento de talhões inteiros da lavoura, possibilitando a identificação de reboleiras de infecção e a otimização da aplicação localizada de defensivos, um passo crucial para a implementação da agricultura de precisão em larga escala e para um manejo mais sustentável da cultura do café.

Referências

- ARAVIND, K. R.; RAJA, P. *Automated disease classification in plant leaves using deep learning*. In: international conference on computing, communication and networking technologies (icccnt), 11., 2020, kharagpur. Anais... Kharagpur: iee, 2020. P. 1-6.
- ATILA, Ü.; UÇAR, M.; AKYOL, K.; UÇAR, E. *Plant leaf disease classification using deep learning: A review*. Journal of Electronic Imaging, v. 30, n. 2, p. 020901, 2021.
- BARBEDO, J. G. A. *A review on the main challenges in automatic plant disease identification based on visible range images*. Biosystems Engineering, v. 186, p. 32-45, 2019.
- ESGARIO, J. G. M.; KROHLING, R. A.; VENTURA, J. A. *Deep learning for classification and severity estimation of coffee leaf biotic stress*. Computers and Electronics in Agriculture, v. 169, p. 105162, 2020.
- FERENTINOS, K. P. *Deep learning models for plant disease detection and diagnosis*. Computers and Electronics in Agriculture, v. 145, p. 311-318, 2018.
- JEPKOECH, J.; MUGO, D. M.; KENDUIYWO, B. K.; TOO, Edna Chebet. *Arabica coffee leaf images dataset for coffee leaf disease detection and classification*. Data in Brief, v. 36, p. 107142, 2021.
- MOHANTY, S. P.; HUGHES, D. P.; SALATHÉ, M. *Using deep learning for image-based plant disease detection*. Frontiers in Plant Science, v. 7, p. 1419, 2016.
- KAMAL, K. C.; YIN, Z.; WU, M.; WU, Z. *Depthwise separable convolution architectures for plant disease classification*. Computers and Electronics in Agriculture, v. 165, p. 104948, 2019.
- KHAN, M. A.; AKRAM, T.; SHARIF, M.; ALHAISONI, M.; ALZAHARNI, T. N.; BUKHARI, S. A. C. *A lightweight deep learning model for the detection and classification of tomato leaf diseases*. Applied Sciences, v. 11, n. 21, p. 9993, 2021.
- MOHANTY, S. P.; HUGHES, D. P.; SALATHÉ, M. *Using deep learning for image-based plant disease detection*. Frontiers in Plant Science, v. 7, p. 1419, 2016.
- PICON, A.; ALVAREZ-GILA, A.; HAFIDI, M.; ZIA, A.; ECHAZARRA, J. *A deep-learning-based approach for the detection of yellow rust in wheat*. Computers and Electronics in Agriculture, v. 165, p. 104952, 2019.
- SANTOS, J. A. F. dos; MOTTA, V. R. da; VALADÃO, C. T.; CUADROS, M. A. de S. L. *Automação do Teste de Compressão de Pelotas de Minério de Ferro Através de Visão Computacional*. In: ENCONTRO ANUAL DE CIÊNCIA DA COMPUTAÇÃO (ENACOMP), 15., 2020, Catalão. Anais... Catalão: Universidade Federal de Catalão, 2020. p. 27-36.
- SLADOJEVIC, S.; ARSENOVIC, M.; ANDERLA, A.; CULIBRK, D.; STEFANOVIC, D. *Plant disease detection and classification using deep neural networks*. In: *international conference on systems, signals and image*

processing (iwSSIP), 23., 2016, Bratislava. Anais. Bratislava: IEEE, 2016. p. 1-5.

TOO, E. C.; YUJIAN, L.; NJUKI, S.; YINGCHUN, L. A *comparative study of fine-tuning deep learning models for plant disease identification*. Computers and Electronics in Agriculture, v. 161, p. 272-279, 2019.